



**SISTEM DETEKSI TINGKAT NAFSU MAKAN IKAN MUJAIR
BERBASIS ANALISIS PERILAKU AGREGASI DAN SISA
PAKAN MENGGUNAKAN YOLOV8**

Proposal Skripsi

diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Teknik

oleh
Nanda Willy Atmaja
5312422021

**TEKNIK KOMPUTER
FAKULTAS TEKNIK
UNIVERSITAS NEGERI SEMARANG
SEMARANG, 2025**

PERSETUJUAN PEMBIMBING

Skripsi berjudul “ Sistem deteksi tingkat nafsu makan ikan mujair berbasis analisis perilaku agregasi dan sisa pakan menggunakan Yolov8” yang disusun oleh

Nama : Nanda Willy Atmaja

NIM : 5312422021

Prodi/Fakultas : Teknik Komputer/Teknik

telah disetujui untuk diajukan ke penilaian proposal.

Semarang,

Pembimbing

Tatyantoro Andrasto, S.T., M.T.

196803161999031001

DAFTAR ISI

PERSETUJUAN PEMBIMBING.....	i
DAFTAR ISI.....	ii
DAFTAR TABEL.....	iv
DAFTAR GAMBAR	v
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Batasan Masalah	2
1.3 Rumusan Masalah	3
1.4 Tujuan Penelitian.....	4
1.5 Manfaat Penelitian	4
1.6 Kebaruan Penelitian	5
BAB II KAJIAN PUSTAKA	7
2.1 Tinjauan Pustaka	7
2.1.1 Penelitian Terkait Deteksi Perilaku Ikan	7
2.1.2 Penelitian Terkait Deteksi Sisa Pakan	7
2.1.3 Penelitian Terkait Algoritma YOLO pada Lingkungan Air	8
2.1.4 Posisi Penelitian	9
2.2 Landasan Teoretik	9
2.2.1 <i>Deep Learning</i> dan Ekstraksi Fitur Otomatis	9
2.2.2 Arsitektur YOLOv8 (<i>Anchor-Free Detection</i>)	10
2.2.3 Karakteristik Visual Ikan Mujair (<i>Oreochromis mossambicus</i>).....	11
2.2.4 Metrik Evaluasi Kinerja Sistem	13
BAB III METODE PENELITIAN.....	15
3.1 Pendekatan, Jenis, dan Prosedur Penelitian	15
3.1.1 Pendekatan Penelitian	15
3.1.2 Jenis Penelitian.....	15
3.1.3 Prosedur Penelitian	15
3.2 Lokasi dan Waktu Penelitian.....	17
3.2.1 Lokasi Penelitian.....	17
3.2.2 Waktu Penelitian	18
3.3 Subjek Penelitian, Populasi, dan Sampel	18

3.3.1	Subjek Penelitian.....	18
3.3.2	Populasi Data	18
3.3.3	Sampel Data (Dataset).....	18
3.4	Variabel Penelitian dan Definisi Operasional	19
3.4.1	Variabel Penelitian	19
3.4.2	Definisi Operasional	19
3.5	Hipotesis Penelitian.....	20
3.6	Data dan Sumber Data	21
3.7	Teknik Pengumpulan Data	22
3.8	Teknik Keabsahan Data (<i>Data Validity</i>).....	23
3.9	Teknik Analisis Data	23
3.9.1	Lingkungan Komputasi.....	24
3.9.2	Metrik Evaluasi Model (Confusion Matrix)	24
3.9.3	Analisis Logika Nafsu Makan.....	26
3.10	Etika Penelitian	28
DAFTAR PUSTAKA.....		29
LAMPIRAN 1.....		32
LAMPIRAN 2.....		34
LAMPIRAN 3.....		35

DAFTAR TABEL

Tabel A. 1 Spesifikasi Hardware	27
Tabel B. 1 Spesifikasi Softawre	27
Tabel C. 1 Definisi Kelas Dataset	27
Tabel D. 1 Lembar Confusion Matrix	28
Tabel D. 2 Lembar Hasil Perhitungan Metrik Evaluasi	28
Tabel D. 3 Lembar Pengujian Kecepatan Inferensi	28

DAFTAR GAMBAR

Gambar 2.1 Diagram Blok Arsitektur YOLOv8 yang terdiri dari Backbone, Neck, dan Head (Sumber: Diolah dari Jocher et al., 2023)	11
Gambar 2.2 Ilustrasi Perbedaan Pola Distribusi Ikan.	12
Gambar 2.3 Visualisasi Perhitungan Intersection over Union (IoU) yang Membandingkan Area Irisan (Intersection) terhadap Area Gabungan (Union). ...	14
Gambar 3.1 Diagram Alir (Flowchart) Tahapan Penelitian	16
Gambar 3.2 Contoh Visualisasi Confusion Matrix untuk Kelas Ikan	25
Gambar 3.3 Diagram Alir Logika Penentuan Status Nafsu Makan Berbasis Rule-Based	27

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sektor akuakultur merupakan pilar vital dalam ketahanan pangan global, khususnya dalam penyediaan sumber protein hewani. Laporan terbaru Food and Agriculture Organization (FAO) menyebutkan bahwa produksi akuakultur global terus mencatatkan rekor tertinggi, melampaui perikanan tangkap sebagai penyumbang utama ikan konsumsi dunia (FAO, 2024). Indonesia, dengan kekayaan biodiversitas perairannya, memiliki potensi besar untuk mengembangkan sektor ini secara berkelanjutan. Salah satu komoditas unggulannya adalah ikan mujair atau tilapia (*Oreochromis spp.*). Ikan ini menjadi primadona pembudidaya karena toleransi lingkungan yang tinggi, resistensi terhadap penyakit, serta laju pertumbuhan yang cepat, menjadikannya salah satu spesies paling ekonomis untuk dibudidayakan secara intensif (Abdel-Tawwab et al., 2021).

Meskipun memiliki potensi besar, produktivitas akuakultur masih dihadapkan pada tantangan efisiensi pakan. Pakan merupakan komponen biaya terbesar dalam budidaya intensif, yang sering kali mencakup hingga 70% dari total biaya operasional (Zhao et al., 2021). Manajemen pemberian pakan yang tidak presisi berdampak fatal; pemberian pakan berlebih (*overfeeding*) tidak hanya merugikan secara finansial tetapi juga mendegradasi kualitas air akibat penumpukan limbah organik. Hal ini dipertegas oleh Hu et al. (2021), yang mengembangkan metode deteksi *real-time* untuk menghitung pelet sisa pakan di dasar kolam. Penelitian mereka membuktikan bahwa deteksi visual yang akurat terhadap sisa pakan adalah indikator paling objektif untuk menghentikan pemberian pakan tepat waktu, sehingga mencegah lonjakan kadar nitrogen yang berbahaya bagi ekosistem tambak (Ubina et al., 2021).

Hingga saat ini, penilaian nafsu makan ikan di lapangan mayoritas masih dilakukan secara manual berdasarkan pengamatan visual pembudidaya. Metode konvensional ini memiliki kelemahan mendasar karena bersifat subjektif dan sulit distandardisasi, terutama pada kondisi air keruh atau pencahayaan yang berubah-ubah (Yang, L. et al., 2021). Ketergantungan pada intuisi manusia ini menjadi penghambat utama dalam transisi menuju smart aquaculture, yang menuntut data

objektif dan real-time untuk pengambilan keputusan yang berkelanjutan (Wu et al., 2025).

Perkembangan pesat kecerdasan buatan (Artificial Intelligence/AI) dan visi komputer (Computer Vision) menawarkan solusi fundamental untuk pemantauan perilaku secara otomatis dan non-invasif (Yang, X. et al., 2021). Secara khusus, algoritma deep learning seperti YOLO (You Only Look Once) telah membuktikan keunggulannya dalam mendeteksi objek secara cepat di lingkungan akuatik yang dinamis. Versi terbaru, YOLOv8, menawarkan arsitektur yang lebih efisien dibandingkan pendahulunya, menjadikannya kandidat ideal untuk sistem deteksi berbasis video yang membutuhkan latensi rendah (Jocher & Chaurasia, 2023).

Penelitian terkini menunjukkan bahwa model deteksi objek dapat dilatih untuk mengenali pola perilaku makan ikan, yang secara spesifik ditandai dengan peningkatan intensitas agregasi atau perilaku bergerombol (Pitcher & Parrish, 1993). Selain analisis perilaku, sistem cerdas kini dikembangkan untuk mendeteksi intensitas makan (feeding intensity) guna mengatur jadwal pemberian pakan secara otomatis (Adegboye et al., 2020). Integrasi antara deteksi perilaku agregasi dan pemantauan intensitas makan ini dapat memberikan gambaran komprehensif mengenai status kekenyangan ikan, memungkinkan penghentian pemberian pakan yang tepat waktu untuk meminimalkan limbah.

Berdasarkan urgensi tersebut, penelitian ini difokuskan pada pengembangan sistem deteksi tingkat nafsu makan ikan mujair berbasis analisis perilaku agregasi menggunakan algoritma YOLOv8. Pemanfaatan perangkat sederhana seperti webcam dan komputer jinjing dalam penelitian ini diharapkan dapat menghasilkan solusi teknologi yang low-cost namun akurat, sehingga dapat diaplikasikan secara luas untuk mendukung efisiensi budidaya perikanan modern.

1.2 Batasan Masalah

Agar penelitian ini lebih terarah dan dapat diselesaikan sesuai dengan lingkup waktu serta sumber daya yang tersedia, maka batasan masalah ditetapkan sebagai berikut:

1. Penelitian dilakukan menggunakan ikan mujair (*Oreochromis mossambicus*) pada wadah akuarium kaca skala laboratorium (lingkungan

- terkontrol), tidak mencakup pengujian pada kolam tanah atau tambak terbuka.
2. Pengambilan data citra dilakukan menggunakan kamera webcam standar atau kamera laptop dengan resolusi terbatas, tanpa menggunakan kamera industri atau kamera bawah air khusus.
 3. Algoritma yang digunakan dibatasi pada YOLOv8n (nano) untuk mendeteksi dua kelas objek utama: ikan dan butiran pakan terapung. Tidak dilakukan perbandingan dengan algoritma deteksi objek lainnya.
 4. Fokus parameter yang diamati adalah perilaku agregasi (berkumpulnya ikan) dan estimasi sisa pakan secara visual. Penelitian ini tidak mengukur parameter biologi internal ikan (seperti bedah lambung) atau parameter kualitas air (suhu, pH, DO).
 5. Pengambilan data dilakukan pada kondisi lingkungan luar ruangan (*outdoor*) dengan pencahayaan alami matahari. Penelitian ini membatasi pengambilan data pada waktu siang hari (pukul 08.00–16.00 WIB) untuk memastikan visibilitas objek tetap terjaga, dan tidak mencakup kondisi malam hari atau cuaca hujan ekstrem.
 6. Hasil akhir penelitian berupa sistem perangkat lunak yang mampu memberikan status tingkat nafsu makan lapar/kenyang, dan tidak mencakup perancangan perangkat keras mekanik (*hardware*) untuk penebar pakan otomatis.

1.3 Rumusan Masalah

Berdasarkan latar belakang dan batasan masalah yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

- a. Bagaimana performa akurasi dan kecepatan algoritma YOLOv8n dalam mendeteksi objek ikan mujair dan sisa pakan secara *real-time* pada media akuarium?.
- b. Bagaimana merancang logika penentuan tingkat nafsu makan ikan berdasarkan parameter kepadatan agregasi dan jumlah sisa pakan yang terdeteksi?.

- c. Seberapa akurat tingkat keberhasilan sistem dalam mengklasifikasikan status nafsu makan ikan jika dibandingkan dengan pengamatan manual?.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk mengembangkan sistem deteksi tingkat nafsu makan ikan mujair berbasis visi komputer yang efisien dan *low-cost*. Adapun tujuan spesifik dari penelitian ini adalah:

- a. Mengukur Kinerja Model Deteksi: Mengimplementasikan dan menguji performa algoritma YOLOv8n dalam mendeteksi objek ikan dan sisa pakan pada lingkungan akuarium, ditinjau dari aspek akurasi (*Precision, Recall, mAP*) dan kecepatan pemrosesan (*Frames Per Second/FPS*) pada perangkat laptop standar.
- b. Membangun Logika Penentuan Nafsu Makan: Merancang algoritma yang mampu mengintegrasikan data perilaku agregasi ikan (kepadatan/pergerakan) dan estimasi jumlah sisa pakan untuk menghasilkan status tingkat nafsu makan secara kuantitatif (Lapar dan Kenyang).
- c. Validasi Sistem: Mengevaluasi tingkat keberhasilan sistem dalam memberikan keputusan status nafsu makan ikan dibandingkan dengan pengamatan manual, guna memastikan sistem dapat beroperasi secara objektif dan *real-time*.

1.5 Manfaat Penelitian

Penelitian ini diharapkan memberikan manfaat signifikan baik dari sisi pengembangan ilmu pengetahuan maupun penerapannya dalam teknologi akuakultur, yang diuraikan sebagai berikut:

- a. Manfaat Teoretis

Penelitian ini diharapkan dapat memperkaya kajian di bidang *Computer Vision*, khususnya terkait pemanfaatan algoritma ringan seperti YOLOv8n untuk mengenali objek yang bergerak pada lingkungan akuatik dengan kondisi yang terbatas. Selain itu, penelitian ini diarahkan untuk mengembangkan pendekatan deteksi non-invasif yang dapat menjadi rujukan bagi penelitian selanjutnya dalam pengukuran parameter biologis

ikan, terutama nafsu makan, dengan memanfaatkan teknologi kecerdasan buatan. Penelitian ini juga bertujuan untuk membuktikan secara empiris adanya hubungan antara pola pengelompokan ikan dan keberadaan sisa pakan sebagai indikator yang dapat digunakan untuk menentukan tingkat kekenyangan ikan.

b. Manfaat Praktis

Penelitian ini menawarkan solusi teknologi yang terjangkau dengan menyediakan alternatif sistem pemantauan budidaya yang bersifat *low-cost* dan mudah diakses, sehingga teknologi deteksi visual dapat diterapkan oleh pembudidaya skala kecil maupun laboratorium pendidikan hanya dengan memanfaatkan perangkat standar seperti laptop dan webcam. Selain itu, hasil penelitian ini diharapkan dapat meningkatkan efisiensi budidaya melalui penyediaan alat bantu pengambilan keputusan dalam manajemen pemberian pakan, sehingga pembudidaya mampu menekan biaya produksi yang berkaitan dengan *feed conversion ratio* (FCR) serta mengurangi pencemaran air akibat sisa pakan. Lebih lanjut, penelitian ini dapat menjadi dasar pengembangan sistem berbasis Internet of Things (IoT), dengan berfungsi sebagai purwarupa algoritma visual yang berpotensi diintegrasikan ke dalam sistem *Smart Feeder* pada tahap pengembangan selanjutnya.

1.6 Kebaruan Penelitian

Kebaruan utama (*novelty*) dari penelitian ini terletak pada integrasi dua parameter deteksi—perilaku agregasi biologis dan sisa pakan fisik—menggunakan arsitektur *deep learning* ringan (YOLOv8n) pada lingkungan eksperimental dengan sumber daya terbatas.

Secara spesifik, kontribusi kebaruan penelitian ini meliputi aspek-aspek berikut:

- a. Berbeda dengan penelitian terdahulu yang umumnya mengevaluasi nafsu makan hanya berdasarkan satu indikator (misalnya: hanya perilaku renang atau hanya sisa pakan secara terpisah), penelitian ini mengajukan pendekatan fusi informasi visual. Sistem dirancang untuk mengkorelasikan kepadatan agregasi ikan dengan keberadaan sisa pakan secara simultan

untuk menghasilkan keputusan tingkat nafsu makan yang lebih akurat dan objektif.

- b. Penelitian ini mengisi celah implementasi *Computer Vision* yang sering kali menuntut perangkat keras kelas atas (GPU mahal). Dengan menerapkan algoritma YOLOv8n (Nano), penelitian ini membuktikan bahwa deteksi objek *real-time* yang kompleks dapat dilakukan secara efisien pada perangkat komputasi standar (CPU Laptop), sehingga lebih terjangkau untuk diadopsi.
- c. Kebanyakan riset sebelumnya dilakukan pada skala industri besar atau menggunakan sensor bawah air khusus. Penelitian ini menawarkan kebaruan konteks dengan memvalidasi sistem pada skala mikro (akuarium laboratorium) menggunakan sensor visual sederhana (*webcam*). Pendekatan ini membuka jalan bagi pengembangan *Internet of Things* (IoT) akuakultur yang hemat biaya (*cost-effective*) bagi pembudidaya kecil.

BAB II

KAJIAN PUSTAKA

2.1 Tinjauan Pustaka

Penelitian terkait penerapan kecerdasan buatan (*Artificial Intelligence*) dan visi komputer dalam akuakultur telah banyak dilakukan dalam lima tahun terakhir. Bagian ini menguraikan perkembangan metode yang digunakan peneliti terdahulu serta celah penelitian yang menjadi dasar pengembangan sistem pada penelitian ini.

2.1.1 Penelitian Terkait Deteksi Perilaku Ikan

Aktivitas fisik ikan merupakan bio-indikator utama dalam menilai status kesehatan dan tingkat kekenyangan. Penelitian terdahulu telah mencoba berbagai pendekatan untuk menguantifikasi perilaku ini.

Qiu dan Wang (2025) melakukan studi mendalam mengenai deteksi perilaku ikan menggunakan analisis lintasan dan kohesi kelompok (group cohesion). Mereka mengembangkan model yang mampu melacak pergerakan pencarian makan (foraging movement) untuk mendeteksi intensitas lapar. Meskipun metode ini memberikan akurasi tinggi dalam membedakan ikan lapar dan kenyang berdasarkan kerapatan gerombolan, kelemahannya terletak pada kerentanan terhadap oklusi (ikan saling menutupi) saat populasi sangat padat.

Di sisi lain, pendekatan berbasis klasifikasi video dua tahap (two-stage) juga dikembangkan. Cai et al. (2024) menyoroti penggunaan kerangka kerja yang memisahkan deteksi objek dan pengenalan aktivitas untuk mengenali pola makan. Model ini mampu menangkap fitur temporal dengan sangat baik. Namun, Cai mencatat bahwa kompleksitas komputasi model dua tahap ini sangat tinggi. Implementasinya membutuhkan sumber daya komputasi yang besar, yang sering kali tidak ekonomis bagi pembudidaya skala kecil karena sulit dijalankan secara real-time pada perangkat standar.

2.1.2 Penelitian Terkait Deteksi Sisa Pakan

Selain perilaku ikan, keberadaan sisa pakan atau status kekenyangan (satiety) merupakan variabel kritis untuk mencegah overfeeding. Mendeteksi pelet pakan yang berukuran kecil di permukaan air yang bergelombang memiliki tantangan tersendiri.

Zhao et al. (2021) dalam tinjauan komprehensifnya mencatat bahwa metode visi komputer konvensional sering digunakan untuk memisahkan objek pakan dari latar belakang air. Namun, algoritma ini sering mengalami kesulitan membedakan pakan dengan objek asing lain yang memiliki warna serupa, seperti buih atau limbah organik, terutama di kolam outdoor.

Lebih lanjut, Zhao et al. (2025) menekankan bahwa deteksi visual pakan saja terkadang bias. Dalam eksperimen kekenyangan mereka, ditemukan bahwa pendekatan yang lebih akurat adalah mengintegrasikan fitur visual ikan (postur dan distribusi) sebagai indikator utama, karena ikan yang kenyang akan menunjukkan penurunan respons terhadap pakan. Oleh karena itu, sistem cerdas disarankan tidak hanya bergantung pada satu parameter (pakan saja), melainkan harus mengintegrasikan data perilaku responsif ikan untuk menghindari kesalahan interpretasi.

2.1.3 Penelitian Terkait Algoritma YOLO pada Lingkungan Air

Untuk mengatasi kendala kecepatan (latensi) yang ditemukan pada metode CNN konvensional atau two-stage detector, algoritma deteksi satu tahap (one-stage detector) seperti YOLO (You Only Look Once) menjadi pilihan populer dalam penelitian terbaru.

Zhang et al. (2024) melakukan pengujian kinerja algoritma YOLOv8n (Nano) di lingkungan perairan alami. Hasil penelitian menunjukkan bahwa keluarga algoritma YOLO memiliki ketahanan (robustness) yang lebih baik terhadap variasi pencahayaan bawah air dan masalah oklusi. Secara spesifik, mereka menyoroti bahwa dengan modifikasi pada modul ekstraksi fitur, YOLOv8n mampu mendeteksi ikan yang saling bertumpuk dengan presisi tinggi, yang sangat krusial saat fase pemberian pakan.

Terkait implementasi perangkat keras, Artanto et al. (2025) menguji efisiensi YOLOv8 pada perangkat edge computing (Raspberry Pi). Temuan mereka menunjukkan bahwa YOLOv8 varian Nano menawarkan keseimbangan (trade-off) terbaik antara kecepatan inferensi dan akurasi. Namun, Artanto juga memberikan catatan bahwa meskipun model ini ringan, performanya perlu dioptimalkan lebih lanjut jika harus menangani tugas deteksi ganda (multi-class detection)—yakni

mendeteksi ikan dan pakan sekaligus—agar tetap berjalan lancar (smooth) pada perangkat dengan daya terbatas.

2.1.4 Posisi Penelitian

Berdasarkan penelusuran pustaka di atas, dapat dipetakan beberapa kesenjangan penelitian (*research gap*) yang menjadi fokus studi ini:

1. Kesenjangan Integrasi

Mayoritas penelitian terdahulu (Qiu & Wang, 2025; Zhao et al., 2025) cenderung fokus pada satu aspek mendalam, yaitu analisis perilaku pergerakan atau klasifikasi status kekenyangan saja. Belum banyak sistem yang menggabungkan deteksi perilaku agregasi dan sisa pakan secara simultan dalam satu *pipeline* deteksi ringan.

2. Kesenjangan Komputasi

Solusi yang ada seperti kerangka kerja *two-stage* (Cai et al., 2024) cenderung berat secara komputasi. Hal ini tidak praktis untuk pembudidaya rakyat yang umumnya hanya memiliki perangkat laptop standar tanpa GPU khusus.

Oleh karena itu, penelitian ini memposisikan diri untuk mengisi celah tersebut dengan mengembangkan sistem deteksi nafsu makan ikan mujair yang mengintegrasikan analisis perilaku agregasi dan sisa pakan menggunakan model YOLOv8n (Nano). Pemilihan model ini didasarkan pada hipotesis bahwa arsitektur ringan YOLOv8n mampu memberikan performa *real-time* pada perangkat *low-end* dengan tingkat akurasi yang masih dapat ditoleransi untuk kebutuhan operasional lapangan.

2.2 Landasan Teoretik

Bagian ini memaparkan teori-teori fundamental yang menjadi kerangka berpikir penelitian, mencakup konsep dasar *Deep Learning*, arsitektur spesifik YOLOv8, etologi ikan mujair, serta metrik evaluasi standar industri.

2.2.1 Deep Learning dan Ekstraksi Fitur Otomatis

Deep Learning merupakan sub-bidang kecerdasan buatan yang menggunakan jaringan saraf tiruan berlapis banyak (*multi-layer neural networks*) untuk mempelajari representasi data. LeCun, Bengio, dan Hinton (2015) dalam

jurnal Nature—yang sering disebut sebagai "bapak Deep Learning"—mendefinisikan bahwa keunggulan fundamental Deep Learning dibandingkan metode visi komputer tradisional adalah kemampuan "representation learning".

Pada metode tradisional, fitur visual (seperti tepi, tekstur, atau bentuk sirip) harus direkayasa secara manual (hand-crafted) oleh manusia. Kelemahannya, fitur manual ini sering gagal ketika kondisi pencahayaan air berubah. Sebaliknya, arsitektur Convolutional Neural Networks (CNN) mampu mengekstraksi fitur tersebut secara otomatis dan berjenjang: lapisan awal mendeteksi garis sederhana, sementara lapisan dalam mendeteksi pola kompleks seperti kerumunan ikan, menjadikannya sangat tangguh (robust) terhadap gangguan lingkungan (noise).

2.2.2 Arsitektur YOLOv8 (*Anchor-Free Detection*)

YOLO adalah algoritma deteksi objek satu tahap (one-stage detector) yang memprioritaskan kecepatan inferensi real-time. Penelitian ini menggunakan versi YOLOv8 yang dikembangkan oleh Ultralytics.


Menurut tinjauan komprehensif Terven dan Cordova-Esparza (2023) dalam jurnal *Engineering Applications of Artificial Intelligence*, evolusi terbesar pada YOLOv8 dibandingkan pendahulunya (YOLOv5/v7) adalah mekanisme Anchor-Free.

1. Pendekatan Lama (Anchor-Based)

Mengandalkan kotak jangkar (anchor boxes) dengan rasio aspek tetap. Ini sering bermasalah saat mendeteksi ikan yang tubuhnya meliuk atau menghadap kamera (aspek rasionya berubah drastis).

2. Pendekatan YOLOv8 (Anchor-Free)

Memprediksi pusat objek secara langsung. Hal ini mengurangi kompleksitas komputasi (NMS lebih cepat) dan meningkatkan fleksibilitas model dalam mengenali objek dengan bentuk geometri yang tidak beraturan, seperti gerombolan ikan yang sedang berebut pakan.



Gambar 2.1 Diagram Blok Arsitektur YOLOv8 yang terdiri dari Backbone, Neck, dan Head (Sumber: Diolah dari Jocher et al., 2023)

Berdasarkan Gambar 2.1, arsitektur YOLOv8 dirancang dengan tiga komponen utama yang bekerja secara sekuensial untuk memproses citra input menjadi hasil deteksi.

Pertama, bagian *Backbone* berfungsi sebagai pengekstraksi fitur (*feature extractor*) yang mengadopsi struktur CSPDarknet53. Komponen kunci di sini adalah modul C2f (*Cross Stage Partial with 2 flow*) yang menggantikan modul C3 pada versi sebelumnya. Modul C2f dirancang dengan jalur aliran gradien yang lebih kaya (*richer gradient flow*) sehingga mampu menangkap fitur visual kompleks dengan beban komputasi yang lebih ringan. Selain itu, pada ujung *backbone* terdapat modul SPPF (*Spatial Pyramid Pooling Fast*) yang bertugas memperluas *receptive field*, memungkinkan model mengenali objek dalam berbagai ukuran tanpa mengorbankan kecepatan pemrosesan.

Kedua, fitur-fitur yang telah diekstraksi diteruskan ke bagian *Neck*. Bagian ini menggunakan struktur PANet (*Path Aggregation Network*) yang dikombinasikan dengan *Feature Pyramid Network* (FPN). Fungsinya adalah menggabungkan fitur semantik tingkat tinggi (informasi jenis objek) dengan fitur spasial tingkat rendah (informasi lokasi/detail pinggiran objek). Mekanisme fusi ini sangat krusial untuk mendeteksi objek kecil seperti butiran pakan agar tidak hilang informasinya saat proses downsampling.

Ketiga, bagian *Head* bertugas menghasilkan prediksi akhir menggunakan pendekatan Anchor-Free dan Decoupled Head. Berbeda dengan YOLO versi lama yang menyatukan tugas klasifikasi dan lokalisasi, YOLOv8 memisahkan (decouple) kedua tugas tersebut ke dalam dua cabang jaringan yang berbeda: satu cabang memprediksi kelas objek (skor probabilitas) dan cabang lain memprediksi koordinat bounding box. Pendekatan anchor-free memprediksi pusat objek secara langsung tanpa memerlukan kotak jangkar pra-definisi, yang terbukti meningkatkan akurasi *Intersection over Union* (IoU) dan mempercepat proses *Non-Maximum Suppression* (NMS) pada tahap akhir.

2.2.3 Karakteristik Visual Ikan Mujair (*Oreochromis mossambicus*)

Ikan Mujair adalah spesies Cichlidae yang dikenal memiliki toleransi lingkungan tinggi. Abdel-Tawwab et al. (2021) menjelaskan bahwa meskipun tahan banting, ikan ini memiliki respons fisiologis yang cepat terhadap stresor, termasuk kelaparan.

Dalam konteks etologi (ilmu perilaku), Arechavala-Lopez et al. (2022) dalam *Reviews in Aquaculture* menjelaskan konsep Plastisitas Perilaku Kelompok. Secara naluriah, ikan memiliki dua mode renang utama:


1. Mode Eksplorasi (Lapar)

Ikan meningkatkan kohesi kelompok (shoaling) dan berenang menuju permukaan atau area yang diasosiasikan dengan pakan. Kepadatan visual meningkat drastis di area ini.

2. Mode Istirahat (Kenyang)

Setelah kebutuhan metabolik terpenuhi, motivasi sosial menurun, menyebabkan kelompok menyebar (dispersal) ke seluruh kolom air dengan vektor pergerakan yang lambat. Perbedaan kontras antara fase Padat-Cepat

(Lapar) dan Menyebar-Lambat (Kenyang) inilah yang menjadi landasan biologis deteksi visual.



Gambar 2.2 Ilustrasi Perbedaan Pola Distribusi Ikan.

Perbedaan pola spasial ikan mujair pada fase lapar dan kenyang diilustrasikan pada Gambar 2.2. Pada kondisi lapar, ikan secara naluriah menunjukkan perilaku kohesi sosial yang tinggi atau disebut *shoaling*, di mana individu cenderung berkumpul membentuk kelompok padat untuk meningkatkan efisiensi pencarian pakan. Sebaliknya, setelah kebutuhan metabolik terpenuhi atau dalam kondisi kenyang, motivasi sosial menurun drastis sehingga ikan cenderung memisahkan diri (*dispersal*) dan menyebar ke seluruh kolom air dengan pergerakan yang lebih lambat. Perubahan visual dari pola mengelompok menjadi menyebar inilah yang dijadikan parameter utama deteksi oleh sistem Computer Vision.

2.2.4 Metrik Evaluasi Kinerja Sistem

Untuk menjamin validitas kinerja model secara kuantitatif, digunakan protokol evaluasi standar berdasarkan Confusion Matrix. Padilla et al. (2020) menjabarkan formulasi matematis parameter kunci sebagai berikut:

a. Precision (P)

Mengukur seberapa akurat prediksi positif model.

$$Precision = \frac{TP}{TP + FP}$$

b. Recall (R)

Mengukur kemampuan model menemukan seluruh objek positif yang ada.

$$Recall = \frac{TP}{TP + FN}$$

c. Mean Average Precision (mAP)


Rata-rata presisi pada berbagai tingkat *threshold*. mAP@0.5 sering digunakan sebagai tolok ukur utama kinerja model YOLO.

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i$$

d. *Intersection over Union* (IoU)

IoU digunakan untuk mengukur seberapa tepat kotak prediksi sistem (B_p) menutupi kotak kebenaran dasar (*ground truth*) B_{gt} pada citra ikan. Nilai IoU berkisar antara 0 hingga 1.

$$IoU = \frac{Area(B_p \cap B_{gt})}{Area(B_p \cup B_{gt})}$$



Gambar 2.3 Visualisasi Perhitungan Intersection over Union (IoU) yang Membandingkan Area Irisan (Intersection) terhadap Area Gabungan (Union).

Konsep perhitungan IoU divisualisasikan pada Gambar 2.3. Kotak berwarna oranye merepresentasikan *Ground Truth* (label manual), sedangkan kotak berwarna biru merepresentasikan *Predicted Box* (hasil deteksi model). Area tumpang tindih berwarna hijau disebut sebagai *Intersection*. Nilai IoU diperoleh dengan membagi luas area hijau tersebut dengan luas total gabungan (*Union*) kedua kotak. Semakin besar area hijau, *semakin* mendekati 1 nilai IoU, yang menandakan posisi deteksi sangat akurat.

BAB III

METODE PENELITIAN

3.1 Pendekatan, Jenis, dan Prosedur Penelitian

3.1.1 Pendekatan Penelitian


Pendekatan yang digunakan dalam penelitian ini adalah pendekatan kuantitatif. Pendekatan ini dipilih karena fokus utama penelitian adalah mengukur kinerja sistem deteksi objek secara objektif menggunakan data numerik. Data yang diolah berupa citra digital yang dikonversi menjadi angka-angka statistik kinerja model, seperti nilai akurasi (*Precision*, *Recall*, *mAP*), nilai kerugian (*loss*), dan kecepatan inferensi (*Frames Per Second*). Penggunaan pendekatan kuantitatif memungkinkan peneliti untuk memberikan penilaian yang terukur terhadap tingkat keberhasilan algoritma YOLOv8n dalam mendeteksi perilaku ikan dan sisa pakan.

3.1.2 Jenis Penelitian

Jenis penelitian ini dikategorikan sebagai penelitian terapan (*applied research*) dengan metode eksperimental. Penelitian terapan bertujuan untuk menerapkan teori atau teknologi yang sudah ada guna memecahkan masalah praktis yang spesifik. Dalam konteks ini, teknologi *Deep Learning* (YOLOv8) diterapkan untuk mengatasi masalah efisiensi pemberian pakan pada budidaya ikan mujair. Sifat eksperimental terlihat dari adanya manipulasi kondisi (pemberian pakan) dan kontrol lingkungan (akuarium laboratorium) untuk menguji keandalan sistem yang dikembangkan.

3.1.3 Prosedur Penelitian

Prosedur penelitian dirancang mengikuti alur pengembangan sistem berbasis kecerdasan buatan (AI Development Lifecycle). Secara ringkas, tahapan penelitian digambarkan dalam diagram alir pada Gambar 3.1.



Gambar 3.1 Diagram Alir (Flowchart) Tahapan Penelitian

Adapun penjelasan rinci untuk setiap tahapan tersebut adalah sebagai berikut:

a. Studi Literatur

Mengkaji teori dan penelitian terdahulu mengenai perilaku ikan mujair, karakteristik sisa pakan, dan arsitektur teknis algoritma YOLOv8.

b. Pengumpulan Data (*Data Collection*)

Melakukan perekaman video aktivitas ikan mujair di akuarium pada dua kondisi utama, yaitu saat proses makan (lapar/agregasi tinggi) dan setelah makan (kenyang/menyebar), serta mendokumentasikan kondisi sisa pakan.

c. Pra-pemrosesan Data (*Data Preprocessing*)

1. *Frame Extraction*: Mengubah video menjadi sekumpulan citra (*image frames*).
2. *Data Cleaning*: Memilah citra yang kabur (*blur*) atau tidak relevan.
3. *Annotation*: Memberikan label (*bounding box*) pada objek ikan dan pakan menggunakan perangkat lunak anotasi.
4. *Data Splitting*: Membagi dataset menjadi data latih (*train*), validasi (*val*), dan uji (*test*).

d. Perancangan dan Pelatihan Model (*Training*)

Mengkonfigurasi hiperparameter pada model YOLOv8n dan melatih model menggunakan data latih untuk mengenali pola visual ikan dan pakan.

e. Pengujian dan Evaluasi Model

Menguji model yang telah dilatih menggunakan data uji (*testing set*) dan mengevaluasi hasilnya menggunakan metrik *Confusion Matrix* dan mAP (*Mean Average Precision*).

f. Analisis dan Penarikan Kesimpulan

Menganalisis hasil deteksi untuk merumuskan logika penentuan nafsu makan, serta menarik kesimpulan berdasarkan tujuan penelitian.

3.2 Lokasi dan Waktu Penelitian

3.2.1 Lokasi Penelitian

Penelitian ini dilaksanakan secara mandiri bertempat di kediaman peneliti di Kabupaten Magelang. Pengambilan data dilakukan di area terbuka (*outdoor*) dengan memanfaatkan sumber pencahayaan alami (matahari).

Media penelitian berupa akuarium kaca ditempatkan pada lokasi yang mendapatkan intensitas cahaya cukup untuk kebutuhan visibilitas kamera. Untuk menjaga konsistensi kualitas citra, pengambilan data video difokuskan pada waktu siang hari saat kondisi cuaca cerah hingga berawan, serta menghindari paparan sinar matahari langsung yang terlalu ekstrem (*glare*) pada permukaan air.

3.2.2 Waktu Penelitian

Penelitian ini dilaksanakan dalam rentang waktu mulai bulan Oktober 2025 hingga Januari 2026. Selama periode tersebut, kegiatan penelitian mencakup beberapa tahapan utama, yaitu persiapan alat dan bahan, pengumpulan data, perancangan serta pelatihan model deteksi, hingga pengujian dan analisis hasil. Pembagian waktu ini disusun agar setiap tahapan dapat dilakukan secara sistematis dan terukur, sehingga hasil penelitian yang diperoleh diharapkan sesuai dengan tujuan yang telah ditetapkan.

3.3 Subjek Penelitian, Populasi, dan Sampel

Dalam penelitian berbasis visi komputer, definisi populasi dan sampel berkaitan dengan data citra digital yang akan diolah oleh algoritma.

3.3.1 Subjek Penelitian

Subjek fisik yang diamati dalam penelitian ini adalah ikan mujair (*Oreochromis mossambicus*). Spesifikasi subjek yang digunakan adalah:

- a. Jenis: Ikan mujair fase remaja (*juvenile*) dengan panjang rata-rata 7-10 cm.
- b. Jumlah: Sebanyak 15 ekor dalam satu wadah akuarium.
- c. Kondisi: Ikan dalam keadaan sehat dan aktif.

3.3.2 Populasi Data

Populasi dalam penelitian ini adalah seluruh *frame* video digital yang terekam oleh kamera selama proses eksperimen di luar ruangan (*outdoor*). Populasi ini mencakup variasi kondisi visual akibat perubahan intensitas cahaya matahari (siang dan sore), serta kondisi permukaan air yang mengandung sisa pakan maupun tidak.

3.3.3 Sampel Data (Dataset)

Sampel dalam penelitian ini berupa sekumpulan citra yang disusun menjadi dataset dan dipilih menggunakan teknik *purposive sampling*, dengan kriteria utama

citra harus menampilkan objek ikan dan pakan secara jelas serta dapat dikenali. Dataset awal yang diperoleh berjumlah sekitar 200 hingga 500 citra asli. Mengingat jumlah tersebut masih terbatas, dilakukan penerapan teknik *data augmentation* untuk memperkaya variasi data latih secara sintetis sekaligus meminimalkan potensi terjadinya *overfitting*. Proses augmentasi mencakup transformasi geometris, seperti rotasi, pembalikan horizontal, dan pemotongan acak, serta penyesuaian kondisi pencahayaan melalui pengaturan tingkat kecerahan dan kontras, termasuk penambahan *noise* guna menyerupai kondisi lingkungan luar ruang yang berubah-ubah. Selanjutnya, dataset yang telah melalui proses augmentasi dibagi dengan rasio 80:20, di mana 80% data digunakan sebagai data latih untuk memperbarui bobot model, sedangkan 20% sisanya dimanfaatkan sebagai data validasi untuk mengevaluasi kinerja model selama proses pelatihan.

3.4 Variabel Penelitian dan Definisi Operasional

3.4.1 Variabel Penelitian

Variabel dalam penelitian ini dibagi ke dalam dua kelompok utama, yaitu variabel bebas dan variabel terikat. Variabel bebas merupakan faktor-faktor yang memengaruhi keluaran sistem, yang meliputi frame video digital yang merekam aktivitas ikan serta kondisi permukaan air di akuarium dengan pencahayaan alami (outdoor), serta konfigurasi *hyperparameter* yang digunakan selama proses pelatihan model, seperti jumlah *epoch*, ukuran *batch*, dan *learning rate*. Sementara itu, variabel terikat merupakan variabel yang dihasilkan dari proses pengukuran sistem, yang mencakup nilai kinerja model berupa akurasi deteksi (mAP, *precision*, dan *recall*) serta kecepatan deteksi yang diukur dalam *frame per second* (FPS). Selain itu, variabel terikat juga mencakup hasil klasifikasi akhir sistem yang menyatakan kondisi ikan, yaitu dalam kategori Lapar atau Kenyang.

3.4.2 Definisi Operasional

Untuk menghindari penafsiran ganda, variabel-variabel tersebut didefinisikan secara operasional sebagai berikut:

1. Perilaku Agregasi Ikan (*Fish Aggregation*)

Didefinisikan sebagai tingkat kepadatan visual objek ikan dalam satu area pandang kamera. Dalam sistem ini, agregasi diukur berdasarkan jumlah *bounding box* kelas ikan yang terdeteksi dalam satu *frame*.

1. *Indikator Lapar*: Jumlah deteksi ikan tinggi dan pergerakan acak yang cepat (ikan berebut di permukaan).
 2. *Indikator Kenyang*: Jumlah deteksi ikan di permukaan menurun (ikan turun ke dasar) atau menyebar.
2. Sisa Pakan (*Uneaten Feed*)
- Didefinisikan sebagai objek butiran kecil yang terklasifikasi sebagai kelas 'pakan' yang mengapung di permukaan air.
1. Sisa pakan dihitung berdasarkan jumlah *bounding box* pakan yang terdeteksi secara konsisten selama kurun waktu tertentu setelah penebaran pakan.
3. Tingkat Nafsu Makan (*Appetite Level*)
- Merupakan kesimpulan logika sistem yang ditentukan berdasarkan korelasi antara agregasi dan sisa pakan
1. Status "LAPAR": Jika sistem mendeteksi agregasi ikan tinggi (*High Aggregation*) DAN sisa pakan rendah/nol (*Low Feed Residue*).
 2. Status "KENYANG": Jika sistem mendeteksi agregasi ikan menurun (*Low Aggregation*) DAN sisa pakan mulai terdeteksi banyak (*High Feed Residue*).
4. Pencahayaan Alami (*Natural Lighting*)
- Kondisi penerangan yang bersumber dari sinar matahari langsung maupun tidak langsung. Variabel ini tidak dikontrol secara angka (Lux), namun menjadi kondisi batas dimana data diambil pada rentang waktu siang hari (08.00–16.00 WIB) saat objek terlihat jelas oleh mata manusia.
5. Akurasi Model (mAP@0.5)
- Nilai *Mean Average Precision* pada ambang batas *Intersection over Union* (IoU) 0.5. Ini adalah standar metrik untuk mengukur seberapa tepat kotak deteksi yang dihasilkan model dibandingkan dengan kotak anotasi manual.

3.5 Hipotesis Penelitian

Mengingat penelitian ini bersifat pengembangan sistem (*engineering*), hipotesis yang diajukan adalah hipotesis kinerja sistem (*system performance hypothesis*), bukan hipotesis statistik komparatif. Berdasarkan teori dan kerangka berpikir yang telah dibangun, hipotesis penelitian ini adalah:

1. Hipotesis Akurasi Deteksi

Algoritma YOLOv8n (Nano) yang dilatih dengan teknik augmentasi data mampu mendeteksi objek ikan mujair dan sisa pakan pada kondisi pencahayaan alami (outdoor) dengan nilai rata-rata presisi (Mean Average Precision / mAP@0.5) minimal 80%.

2. Hipotesis Kecepatan Komputasi

Sistem yang dikembangkan mampu beroperasi secara real-time pada perangkat laptop standar (tanpa GPU high-end) dengan kecepatan pemrosesan video minimal 15 FPS (Frames Per Second), sehingga perubahan perilaku ikan dapat dipantau tanpa jeda (delay) yang signifikan.

3. Hipotesis Fungsional

Integrasi parameter perilaku agregasi dan deteksi sisa pakan mampu memberikan kesimpulan status nafsu makan (Lapar atau Kenyang) yang relevan sesuai dengan kondisi visual di lapangan.

3.6 Data dan Sumber Data

Data dalam penelitian ini diklasifikasikan menjadi dua jenis berdasarkan sumber perolehannya:

a. Data Primer

Data primer merupakan data yang diperoleh secara langsung oleh peneliti dari sumber aslinya. Dalam penelitian ini, data primer terdiri atas rekaman video digital berformat *.mp4* yang mendokumentasikan aktivitas ikan mujair di dalam akuarium percobaan. Selain itu, data primer juga berupa dataset citra yang dihasilkan dari proses ekstraksi *frame* video tersebut, yang telah melalui tahap seleksi sehingga hanya mencakup gambar dengan objek target berupa ikan dan pakan, serta merepresentasikan berbagai variasi kondisi pencahayaan matahari.

b. Data Sekunder

Data sekunder merupakan data pendukung yang diperoleh dari sumber pustaka dan tidak dikumpulkan secara langsung melalui proses eksperimen. Dalam penelitian ini, data sekunder meliputi hasil studi literatur berupa jurnal ilmiah, buku teks, serta artikel prosiding konferensi yang membahas karakteristik biologis ikan mujair, konsep dan algoritma *deep learning*, serta

metode deteksi objek. Selain itu, data sekunder juga mencakup dokumentasi teknis, seperti spesifikasi dan panduan penggunaan perangkat lunak YOLOv8 serta informasi terkait perangkat keras yang digunakan dalam penelitian.

3.7 Teknik Pengumpulan Data

Teknik pengumpulan data dalam penelitian ini dilakukan melalui beberapa tahapan yang disusun secara sistematis untuk memastikan kualitas dataset yang digunakan dalam proses pelatihan model kecerdasan buatan. Tahap pertama adalah observasi dan perekaman data, yang dilakukan dengan merekam aktivitas ikan menggunakan kamera berupa webcam atau *smartphone* yang diposisikan secara *top-down* (tegak lurus dari atas) maupun *side-view* (dari samping) terhadap akuarium. Perekaman dilakukan di lokasi penelitian dengan kondisi luar ruang (*outdoor*) pada rentang waktu pukul 08.00 hingga 16.00 WIB guna memperoleh variasi intensitas cahaya matahari. Video direkam pada dua kondisi utama, yaitu saat fase lapar atau pemberian pakan, ketika pakan ditebar dan ikan menunjukkan perilaku berebut makan dengan tingkat agregasi yang tinggi, serta pada fase kenyang, yakni sekitar 15–30 menit setelah pemberian pakan, ketika sisa pakan mulai terlihat dan ikan cenderung menyebar.

Tahap selanjutnya adalah ekstraksi dan pemilahan citra, di mana video hasil perekaman dipecah menjadi citra diam (*frame*) dengan interval waktu tertentu, misalnya satu gambar setiap lima detik. Dari hasil ekstraksi tersebut, dilakukan proses *data cleaning* secara manual untuk menghilangkan citra yang kabur, memiliki pencahayaan terlalu gelap atau terlalu terang, serta citra yang tidak memuat objek target. Citra yang telah terseleksi kemudian masuk ke tahap anotasi data, yaitu pemberian label secara manual menggunakan perangkat lunak anotasi seperti Roboflow atau LabelImg. Label yang digunakan terdiri dari dua kelas, yaitu *ikan* untuk objek tubuh ikan mujair dan *pakan* untuk butiran pakan yang mengapung di permukaan air, dengan format anotasi disimpan dalam berkas *.txt* sesuai standar YOLO.

Tahap terakhir adalah augmentasi data. Mengingat jumlah data asli yang relatif terbatas, yaitu sekitar 200 hingga 500 citra, diterapkan teknik *data augmentation* untuk memperkaya variasi data latih secara sintesis. Augmentasi

dilakukan melalui transformasi geometris berupa rotasi gambar dengan rentang ± 15 derajat dan pembalikan horizontal, serta penyesuaian kondisi pencahayaan dengan mengubah tingkat kecerahan sebesar $\pm 20\%$ untuk mensimulasikan perbedaan kondisi cuaca, seperti mendung maupun terik.

3.8 Teknik Keabsahan Data (*Data Validity*)

Untuk memastikan bahwa data dan model yang dihasilkan bersifat valid serta meminimalkan potensi bias, penelitian ini menerapkan beberapa teknik validasi yang umum digunakan dalam *machine learning*. Salah satu langkah utama yang dilakukan adalah pemisahan data (*data splitting*) secara terkontrol, dengan tujuan agar model tidak sekadar menghafal data. Dataset dibagi menjadi data latih sebesar 80% yang digunakan untuk proses pembelajaran bobot model, serta data validasi sebesar 20% yang dimanfaatkan untuk memantau kinerja model selama proses pelatihan dan mendeteksi gejala *overfitting*. Selain itu, dilakukan pula pengujian lapangan secara opsional dengan menggunakan video baru yang direkam pada hari yang berbeda, guna mengevaluasi ketahanan model terhadap perubahan kondisi pencahayaan alami.

Validasi juga dilakukan melalui verifikasi *ground truth*, yaitu dengan melakukan pengecekan ulang secara acak terhadap hasil anotasi manual berupa *bounding box* yang telah dibuat. Langkah ini bertujuan untuk memastikan bahwa label benar-benar merepresentasikan posisi dan ukuran objek ikan maupun pakan secara tepat sebelum digunakan dalam proses pelatihan. Apabila hasil validasi awal menunjukkan performa yang belum stabil, maka dapat diterapkan metode *K-Fold Cross Validation* sebagai langkah tambahan untuk menguji konsistensi kinerja model pada berbagai pembagian data yang berbeda.

3.9 Teknik Analisis Data

Analisis data dalam penelitian ini dilakukan secara kuantitatif dengan tujuan untuk mengukur kinerja sistem deteksi yang dikembangkan serta mengevaluasi keberhasilan logika yang digunakan dalam menentukan kondisi nafsu makan ikan. Pendekatan kuantitatif dipilih agar hasil analisis dapat dinyatakan dalam bentuk nilai numerik yang objektif dan terukur, sehingga memudahkan proses evaluasi dan

perbandingan kinerja sistem. Melalui analisis ini, kinerja model deteksi dan ketepatan klasifikasi kondisi ikan dapat dinilai secara sistematis berdasarkan indikator yang telah ditetapkan.

3.9.1 Lingkungan Komputasi

Mengingat keterbatasan perangkat keras yang tersedia, proses analisis dalam penelitian ini dibagi ke dalam dua lingkungan kerja yang berbeda. Proses pelatihan (*training*) model dilakukan menggunakan layanan komputasi awan Google Colab yang menyediakan dukungan akselerasi GPU, seperti NVIDIA T4, sehingga proses pembelajaran model dapat berjalan lebih cepat dan efisien. Sementara itu, proses pengujian (*inference*) dilakukan secara lokal pada sebuah laptop dengan spesifikasi prosesor AMD Ryzen 5 5500U yang dilengkapi grafis terintegrasi Radeon Graphics. Pengujian lokal ini bertujuan untuk mengevaluasi kinerja model dalam kondisi penggunaan nyata, khususnya dalam skenario pemrosesan *real-time* pada perangkat yang mewakili pengguna akhir.

3.9.2 Metrik Evaluasi Model (Confusion Matrix)

Kinerja deteksi YOLOv8n dalam penelitian ini dievaluasi menggunakan *confusion matrix* sebagai dasar pengukuran performa. Matriks ini terdiri atas beberapa komponen utama, yaitu *true positive* (TP) yang menunjukkan kondisi ketika sistem berhasil mendeteksi objek ikan atau pakan sesuai dengan fakta di lapangan. Selanjutnya, *false positive* (FP) menggambarkan kesalahan deteksi, misalnya ketika sistem mengidentifikasi objek non-target seperti gelembung air sebagai pakan. Sementara itu, *false negative* (FN) merepresentasikan kondisi ketika sistem gagal mendeteksi objek yang seharusnya muncul dalam citra. Melalui analisis komponen-komponen tersebut, kinerja model dapat dievaluasi secara lebih menyeluruh dan objektif.

Dari parameter tersebut, dihitung nilai:

1. Precision (Presisi): Tingkat ketepatan deteksi positif.


$$Precision = \frac{TP}{TP + FP}$$

2. Recall (Sensitivitas): Tingkat keberhasilan menemukan seluruh objek.

$$Recall = \frac{TP}{TP + FN}$$

3. Mean Average Precision (mAP@0.5):

Rata-rata presisi dari seluruh kelas (ikan dan pakan) pada ambang batas Intersection over Union (IoU) sebesar 0.5. Nilai ini menjadi tolok ukur utama keberhasilan model.



Gambar 3.2 Contoh Visualisasi Confusion Matrix untuk Kelas Ikan

Gambar 3.2 menyajikan ilustrasi visualisasi *Confusion Matrix* yang digunakan untuk memetakan hasil prediksi model terhadap data aktual. Pada matriks tersebut, sumbu vertikal merepresentasikan kelas yang diprediksi oleh sistem (*Predicted*), sedangkan sumbu horizontal merepresentasikan kebenaran dasar (*True*). Sebagai contoh interpretasi pada kelas *fish* (ikan), nilai 542 yang terletak pada diagonal utama dengan warna biru pekat menunjukkan *True Positive* (TP), yaitu jumlah objek ikan yang berhasil dideteksi secara tepat oleh model. Sementara itu, nilai 178 pada kuadran kanan atas merupakan FP, yang mengindikasikan adanya kesalahan deteksi di mana objek latar belakang (*background*) dianggap sebagai ikan oleh sistem. Adapun nilai 134 pada kuadran kiri bawah merepresentasikan FN, yaitu jumlah objek ikan yang gagal dideteksi atau terlewat oleh sistem. Akumulasi nilai-nilai dari matriks inilah yang selanjutnya

dikalkulasi menggunakan persamaan presisi dan sensitivitas untuk menentukan skor akhir kinerja model.


3.9.3 Analisis Logika Nafsu Makan

Data hasil deteksi yang diperoleh dari model, berupa koordinat *bounding box* dan jumlah objek yang teridentifikasi, selanjutnya dianalisis menggunakan logika *rule-based* sederhana untuk menentukan status kondisi ikan. Dalam analisis ini digunakan dua variabel utama, yaitu N_{ikan} yang merepresentasikan jumlah objek ikan yang terdeteksi pada setiap *frame*, serta N_{pakan} yang menunjukkan jumlah objek sisa pakan yang terdeteksi pada setiap *frame*. Kedua variabel tersebut menjadi dasar dalam penentuan kondisi akhir ikan pada setiap pengamatan.

Status nafsu makan (S) ditentukan dengan aturan:

$$S = \begin{cases} \text{LAPAR,} & \text{jika } N_{ikan} \geq \alpha \text{ dan } N_{pakan} \leq \beta \\ \text{KENYANG,} & \text{jika } N_{ikan} < \alpha \text{ dan } N_{pakan} > \beta \end{cases}$$

Dimana α (ambang batas agregasi) dan β (ambang batas sisa pakan) ditentukan berdasarkan hasil observasi rata-rata data latih. Alur logika penentuan keputusan tersebut divisualisasikan dalam bentuk diagram alir pada Gambar 3.3.



Gambar 3.3 Diagram Alir Logika Penentuan Status Nafsu Makan Berbasis Rule-Based

3.10 Etika Penelitian

Penelitian ini melibatkan makhluk hidup (ikan mujair) sebagai subjek observasi, sehingga peneliti mematuhi prinsip etika kesejahteraan hewan (*animal welfare*) sebagai berikut:

a. Prinsip Non-Invasif

Penelitian ini murni berbasis observasi visual menggunakan kamera (*Computer Vision*). Tidak dilakukan pembedahan, penyuntikan, atau tindakan fisik lain yang menyakiti ikan.

b. Pemeliharaan Standar

Ikan dipelihara dalam kondisi air, suhu, dan aerasi yang layak sesuai standar budidaya. Pakan yang digunakan adalah pakan komersial standar tanpa bahan berbahaya.

c. Minimalisasi Stres

Pengambilan data dilakukan dengan meminimalisir gangguan suara atau gerakan mendadak di sekitar akuarium agar perilaku ikan tetap alami dan tidak stres.

DAFTAR PUSTAKA

- Abdel-Tawwab, M., Monier, M. N., Hoseinifar, S. H., & Faggio, C. (2021). Fish response to hypoxia stress: Growth, physiological, and immunological biomarkers. *Fish Physiology and Biochemistry*, 47(1), 77–89. <https://doi.org/10.1007/s10695-019-00614-9>
- Adegboye, M. A., Aibinu, A. M., Kolo, J. G., Aliyu, I., Sadiku, S. O., & Akerele, K. D. (2020). Incorporating intelligence in fish feeding system for dispensing feed based on fish feeding intensity. *IEEE Access*, 8, 91948–91960. <https://doi.org/10.1109/ACCESS.2020.2994442>
- Arechavala-Lopez, P., Cabrera-Álvarez, M. J., Maia, C. M., & Saraiva, J. L. (2022). Environmental enrichment in fish aquaculture: A review of fundamental and practical aspects. *Reviews in Aquaculture*, 14(2), 704–728. <https://doi.org/10.1111/raq.12620>
- Artanto, G. A., Hanafi, Z., Iman, R. M., & Stefanie, A. (2025). Implementasi YOLOv8 pada sistem deteksi penyakit ikan mas koki menggunakan Raspberry Pi 5. *Jurnal Informatika dan Teknik Elektro Terapan (JITET)*, 13(3). <https://doi.org/10.23960/jitet.v13i3.6770>
- Cai, K., Yang, Z., Gao, T., Liang, M., Liu, P., Zhou, S., & Li, D. (2024). Efficient recognition of fish feeding behavior: A novel two-stage framework pioneering intelligent aquaculture strategies. *Computers and Electronics in Agriculture*, 224, 109129. <https://doi.org/10.1016/j.compag.2024.109129>
- FAO. (2024). *The state of food security and nutrition in the world 2024*. Food and Agriculture Organization of the United Nations. <https://doi.org/10.4060/cd1254en>
- Jocher, G., & Chaurasia, A. (2023). *YOLOv8: Next-generation real-time object detection* [Computer software]. Ultralytics. <https://github.com/ultralytics/ultralytics>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Padilla, R., Netto, S. L., & da Silva, E. A. (2020). A survey on performance metrics for object-detection algorithms. *International Conference on Systems, Signals and Image Processing (IWSSIP)*, 237–242. <https://doi.org/10.1109/IWSSIP48289.2020.9145130>

- Pitcher, T. J., & Parrish, J. K. (1993). Functions of shoaling behaviour in teleosts. In T. J. Pitcher (Ed.), *Behaviour of teleost fishes* (2nd ed., pp. 363–439). Chapman & Hall.
- Qiu, Y.-C., & Wang, K.-J. (2025). Deep learning model for detecting fish foraging movement and distance. *Ecological Informatics*, 92, 103472. <https://doi.org/10.1016/j.ecoinf.2025.103472>
- Terven, J., & Cordova-Esparza, D. (2023). A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS. *Engineering Applications of Artificial Intelligence*, 125, 107038. <https://doi.org/10.1016/j.engappai.2023.107038>
- Ubina, N. A., Cheng, S.-C., Chang, C.-C., & Chen, H.-Y. (2021). Evaluating fish feeding intensity in aquaculture with convolutional neural networks. *Aquacultural Engineering*, 94, 102178. <https://doi.org/10.1016/j.aquaeng.2021.102178>
- Wu, A.-Q., Li, K.-L., Song, Z.-Y., Lou, X., Hu, P., Yang, W., & Wang, R.-F. (2025). Deep learning for sustainable aquaculture: Opportunities and challenges. *Sustainability*, 17(11), 5084. <https://doi.org/10.3390/su17115084>
- Yang, L., Liu, Y., Yu, H., Fang, X., Song, L., Li, D., & Chen, Y. (2021). Computer vision models in intelligent aquaculture with emphasis on fish detection and behavior analysis: A review. *Archives of Computational Methods in Engineering*, 28(4), 2785–2816. <https://doi.org/10.1007/s11831-020-09486-2>
- Yang, X., Zhang, S., Liu, J., Gao, Q., Dong, S., & Zhou, C. (2021). Deep learning for smart fish farming: Applications, opportunities and challenges. *Reviews in Aquaculture*, 13(1), 66–90. <https://doi.org/10.1111/raq.12464>
- Zhang, Z., Qu, Y., Wang, T., Rao, Y., Jiang, D., Li, S., & Wang, Y. (2024). An improved YOLOv8n used for fish detection in natural water environments. *Animals*, 14(14), 2022. <https://doi.org/10.3390/ani14142022>
- Zhao, S., Cai, K., Dong, Y., Feng, G., Wang, Y., Pang, H., & Liu, Y. (2025). Fish feeding behavior recognition via lightweight two stage network and satiety experiments. *Scientific Reports*, 15, 30025. <https://doi.org/10.1038/s41598-025-15241-z>

Zhao, S., Zhang, S., Liu, J., Wang, H., Zhu, J., Li, D., & Zhao, R. (2021). Application of machine learning in intelligent fish aquaculture: A review. *Aquaculture*, 540, 736724. <https://doi.org/10.1016/j.aquaculture.2021.736724>

Hu, X., Liu, Y., Zhao, Z., Liu, J., Yang, X., Sun, C., Chen, S., Li, B., & Zhou, C. (2021). Real-time detection of uneaten feed pellets in underwater images for aquaculture using an improved YOLO-V4 network. *Computers and Electronics in Agriculture*, 185, 106135. <https://doi.org/10.1016/j.compag.2021.106135>

LAMPIRAN 1

A. SPESIFIKASI PERANGKAT KERAS (HARDWARE)

Perangkat keras yang digunakan peneliti untuk melakukan akuisisi data, pelabelan data, pelatihan model (training), dan pengujian sistem (testing) adalah satu unit Laptop/PC dengan spesifikasi sebagai berikut:

Tabel A. 1 Spesifikasi Hardware

No	Komponen	Spesifikasi
1	Merek / Model	Acer Aspire 5
2	Prosesor (CPU)	Ryzen 5 5500u
3	Kartu Grafis (GPU)	IGPU (Vega 7)
4	Memori (RAM)	16 GB DDR4 3200MHz
5	Penyimpanan	SSD 512 GB NVMe M.2
6	Kamera (Webcam)	Kamera HP
7	Monitor	15.6 inch FHD (1920x1080) IPS

B. SPESIFIKASI PERANGKAT LUNAK (SOFTWARE)

Perangkat lunak dan *library* pendukung yang digunakan dalam pengembangan sistem deteksi objek adalah sebagai berikut:

Tabel B. 1 Spesifikasi Software

No	Kategori	Nama Perangkat Lunak / Versi
1	Sistem Operasi	Windows 11 64-bit
2	Bahasa Pemrograman	Python Versi 3.13
3	Framework Deep Learning	PyTorch
4	Arsitektur Model	Ultralytics YOLOv8 (Versi 8.x)
5	IDE / Text Editor	Visual Studio Code
6	Manajemen Environment	Python venv
7	Alat Anotasi Citra	Roboflow / LabelImg
8	Library Pengolahan Citra	OpenCV (Open Source Computer Vision Library)

C. DEFINISI KELAS DATASET

Instrumen data yang digunakan berupa citra digital kolam ikan mujair yang telah dianotasi (diberi label) berdasarkan definisi kelas berikut:

Tabel C. 1 Definisi Kelas Dataset

ID Kelas	Label	Deskripsi Visual Objek
0	ikan (fish)	Ikan mujair yang terlihat jelas di permukaan air atau mendekati permukaan.
1	pakan (pellet)	Butiran pakan terapung yang belum dimakan oleh ikan.

D. LEMBAR PENGUJIAN KINERJA MODEL (TESTING SHEET)

Lembar ini digunakan untuk mencatat hasil eksperimen pengujian deteksi pada video real-time atau data uji.

Tabel D. 1 Lembar Confusion Matrix

Skenario Pengujian	Kelas Objek	True Positive (TP)	False Positive (FP)	False Negative (FN)
Kondisi Cahaya Terang	Ikan			
(Pagi/Siang Hari)	Pakan			
Kondisi Cahaya Redup	Ikan			
(Sore/Mendung)	Pakan			

Tabel D. 2 Lembar Hasil Perhitungan Metrik Evaluasi

Model	Kelas	Precision (%)	Recall (%)	mAP@0.5 (%)
YOLOv8n	Ikan			
(Nano)	Pakan			
	Rata-rata			

Tabel D. 3 Lembar Pengujian Kecepatan Inferensi

Perangkat	Resolusi Input	Waktu Pre-process	Waktu Inference	Waktu Post-process	Total FPS
Laptop	640 x 640	 ms	 ms	 ms	 FPS

LAMPIRAN 2



KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS NEGERI SEMARANG
FAKULTAS TEKNIK

Gedung Dekanat, Kampus Sekaran,
Gunungpati, Semarang 50229.
Telepon: 0248508101
Laman: <http://ft.unnes.ac.id>, surel:
ft@mail.unnes.ac.id

**KEPUTUSAN
DEKAN FAKULTAS TEKNIK
UNIVERSITAS NEGERI SEMARANG
Nomor: B/1828/UN37.1.5/TD.06/2025**

**Tentang
PENETAPAN DOSEN PEMBIMBING SKRIPSI/TUGAS AKHIR SEMESTER GASAL/GENAP
TAHUN AKADEMIK 2025/2026**

- Menimbang : Bahwa untuk memperlancar mahasiswa Prodi Teknik Komputer, S1 Fakultas Teknik membuat Skripsi/Tugas Akhir, maka perlu menetapkan Dosen-dosen Prodi Teknik Komputer, S1 Fakultas Teknik UNNES untuk menjadi pembimbing.
- Mengingat : 1. Undang-Undang Nomor 20 Tahun 2003 tentang Sistem Pendidikan Nasional;
2. Peraturan Pemerintah Nomor 4 Tahun 2014 tentang Penyelenggaraan Pendidikan Tinggi dan Pengelolaan Perguruan Tinggi;
3. Peraturan Pemerintah Nomor 36 Tahun 2022 tentang Perguruan Tinggi Negeri Badan Hukum Universitas Negeri Semarang;
4. Peraturan Rektor Universitas Negeri Semarang Nomor 88 Tahun 2024 tentang Panduan Tugas Akhir Sarjana dan Diploma Universitas Negeri Semarang;
- Menimbang : Usulan Koordinator Prodi Teknik Komputer, S1 Tanggal 2 Oktober 2025

MEMUTUSKAN

- Menetapkan :
PERTAMA : Menunjuk dan menugaskan kepada:
Nama : Tatyantoro Andrasto, S.T., M.T.
NIP : 196803161999031001
Pangkat/Golongan : Pembina Tk. I - IV/b
Jabatan Akademik : Lektor Kepala
Sebagai Pembimbing
Untuk membimbing mahasiswa penyusun skripsi/Tugas Akhir :
Nama : NANDA WILLY ATMAJA
NIM : 5312422021
Prodi : Teknik Komputer, S1
Topik : Penerapan Computer Vision dan Kecerdasan Buatan (AI) dalam bidang Akuakultur Presisi (Precision Aquaculture).
- KEDUA : Keputusan ini mulai berlaku sejak tanggal ditetapkan.

Tembusan
1. WD Bid. Akademik dan Mawa
2. Ketua Prodi
3. Peringgal



5312422021

...: FM-03-AKD-24/Rev. 00 ...

Dokumen ini telah diterbitkan secara elektronik menggunakan sertifikat elektronik yang diterbitkan oleh Balai Besar Sertifikasi Elektronik (BSrE), BSSN.

DITETAPKAN DI : SEMARANG
PADA TANGGAL : 2 Oktober 2025
DEKAN



Prof. Dr. Wirawan Sumbodo, M.T.
NIP 196601051990021002

LAMPIRAN 3



Penulis dilahirkan di Kabupaten Magelang pada tanggal 3 Maret 2003. Penulis merupakan anak ke-1 dari 3 bersaudara. Penulis menempuh pendidikan dasar di SDN Kalisari dan lulus pada tahun 2015. Pendidikan menengah pertama diselesaikan di SMPN 8 Magelang pada tahun 2018, dilanjutkan ke SMKN 1 Magelang jurusan Teknik Komputer dan Jaringan yang diselesaikan pada tahun 2021.

Pada tahun 2022, penulis melanjutkan pendidikan tinggi ke jenjang Strata-1 (S1) pada Program Studi Teknik Komputer, Fakultas Teknik, Universitas Negeri Semarang. Selama menempuh perkuliahan, penulis aktif mengembangkan wawasan di bidang teknologi informasi dan memiliki ketertarikan khusus pada rumpun ilmu Kecerdasan Buatan (Artificial Intelligence), terutama pada penerapan Computer Vision dan Deep Learning.

Minat mendalam terhadap teknologi tersebut memotivasi penulis untuk menyusun tugas akhir dengan judul Sistem deteksi tingkat nafsu makan ikan mujair berbasis analisis perilaku agregasi dan sisa pakan menggunakan YOLOv8. Penelitian ini difokuskan pada pengembangan sistem deteksi objek menggunakan algoritma YOLOv8 untuk mengatasi permasalahan efisiensi pakan di sektor akuakultur. Penulis berharap karya ilmiah ini dapat memberikan kontribusi positif bagi pengembangan ilmu pengetahuan serta bermanfaat bagi para praktisi budidaya perikanan di Indonesia.